PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE

Facultad de Matemáticas / Escuela de Ingeniería

IMT2230 – Álgebra Lineal Avanzada y Modelamiento

Informe Proyecto Computacional: Análisis Semántico Latente (LSA) Mediante Descomposición en Valores Singulares en Artículos de arXiv

Estudiantes:	Damián Bravo, Felipe López
Profesor:	Alexander Kozachinskiy (`alexander.kozachinskyi@cenia.cl`)
Ayudante:	Victoria Otárola (`victoriaotarola@estudiante.uc.cl`)
Repositorio GitHub:	github.com/damian11daba/proyecto-avanzada-y-modelamiento.git
Fecha de Entrega:	Noviembre 2026

Resumen Ejecutivo

En este proyecto implementamos el Análisis Semántico Latente (*Latent Semantic Analysis*, LSA) basado en la Descomposición en Valores Singulares (SVD) para descubrir estructura geométrica y temática en una colección de $n = 200$ resúmenes científicos de acceso abierto recopilados desde la API oficial de arXiv. Los artículos se distribuyen equilibradamente en 4 disciplinas: Inteligencia Artificial, Astrofísica y Cosmología, Genómica y Biología Computacional, y Finanzas Cuantitativas. Construimos una matriz término-documento $A \in \mathbb{R}^{m \times n}$ ($m = 1907$, $n = 200$) mediante ponderación TF-IDF sublineal y calculamos su descomposición $A = U\Sigma V^T$. A través del análisis espectral y el Teorema de Eckart-Young-Mirsky justificamos la reducción a $k = 20$ dimensiones latentes. Derivamos y verificamos rigurosamente las proyecciones ortogonales de términos sobre $\text{Span}(v_a, v_b)$ y de documentos sobre $\text{Span}(u_a, u_b)$, comprobando empíricamente su correspondencia con las columnas escaladas de U y V con una precisión de máquina (10^{-15}). Las representaciones 2D y la similitud coseno confirman la hipótesis inicial: las componentes 2 y 3 separan nítidamente las disciplinas, mientras que palabras polisémicas e interdisciplinarias emergen en la vecindad del origen.

1. Paso 1 – Elección y Descripción del Corpus

Para satisfacer las indicaciones de datos públicos, reproducibles y con sustancia textual, seleccionamos un corpus de **200 resúmenes de artículos científicos** obtenidos desde el servicio oficial de la API de arXiv

(`export.arxiv.org`). Se muestrearon 50 artículos por categoría para cuatro disciplinas del modelamiento matemático contemporáneo:

- **Inteligencia Artificial (`cs.AI`):** Modelos fundacionales, aprendizaje por refuerzo, razonamiento en agentes autónomos.
- **Astrofísica y Cosmología (`astro-ph.CO`):** Materia oscura, lentes gravitacionales, estructura a gran escala de galaxias.
- **Genómica y Biología Computacional (`q-bio.GN`):** Secuenciación de ARN/ADN, perfiles de expresión génica, mutaciones.
- **Finanzas Cuantitativas (`q-fin.PM`):** Optimización estocástica de portafolios, fijación de precios de activos, primas de riesgo.

Categoría	Código arXiv	N° Docs (n)	Palabras Promedio	Mín.	Máx.	Desv. Est.
Inteligencia Artificial	`cs.AI`	50	207.76	103	294	42.08
Astrofísica y Cosmología	`astro-ph.CO`	50	210.10	108	292	44.26
Genómica y Biología Computacional	`q-bio.GN`	50	207.36	124	324	42.06
Finanzas Cuantitativas	`q-fin.PM`	50	190.80	40	301	61.47
Total Global	--	**200**	**204.01**	**40**	**324**	**47.47**

2. Paso 2 – Hipótesis Inicial

> ***Hipótesis Formulada:***
> *Anticipamos que los valores singulares decaerán rápidamente bajo una ley de potencias, concentrando la estructura principal en pocas componentes. La primera componente singular (u_1, v_1) no discriminará temáticas, sino que capturará un factor de escala común correspondiente a la longitud y vocabulario académico ubicuo (data, model, analysis, results). Por su parte, las componentes 2, 3 y 4 actuarán como ejes ortogonales discriminatorios que separarán nítidamente las disciplinas en cuadrantes independientes. Finalmente, predecimos que los términos de modelamiento interdisciplinarios (optimization, parameters, distribution) se posicionarán próximos al origen del plano latente, reflejando su presencia compartida.*

3. Paso 3 – Preprocesamiento del Texto

Para garantizar un vocabulario libre de ruido estocástico y términos espurios, se adoptaron las siguientes decisiones de preprocesamiento:

1. **Normalización léxica:** Conversión a minúsculas, filtrado de caracteres no alfabéticos y selección de tokens de longitud ≥ 3.
2. **Eliminación de Stopwords:** Remoción de stopwords estándar en inglés de `scikit-learn`, más 25 términos genéricos de redacción académica (*paper, study, proposed, method, results, show, demonstrate, etc.*).
3. **Filtrado por Frecuencia Documental:**
   - `min_df = 3`: Descarta palabras que aparecen en menos de 3 documentos (elimina erratas, nombres de autores aislados).
   - `max_df = 0.60`: Descarta palabras presentes en más del 60% del corpus (ubicuidad).
4. **TF-IDF Sublineal:** Se calculó $\text{TF-IDF}(t,d) = (1 + \log(\text{tf}(t,d))) \times (\log \frac{1+n}{1+\text{df}(t)} + 1)$ con normalización euclídea (L_2), amortiguando el impacto de términos muy repetidos en documentos extensos.

El vocabulario final resultante contiene $m = 1907$ **términos** significativos.

4. Paso 4 – Construcción de la Matriz Textual A

De acuerdo a la pauta, las filas de la matriz representan términos (m) y las columnas documentos (n):

$$A \in \mathbb{R}^{m \times n}, \quad m = 1907, \quad n = 200$$

Dado que `TfidfVectorizer` genera internamente una matriz con documentos en las filas ($X \in \mathbb{R}^{n \times m}$), se aplicó la transposición explícita:

$$A = X^T \in \mathbb{R}^{m \times n}$$

La matriz A posee una densidad de elementos no nulos del 3.71%.

5. Paso 5 – Cálculo de la Descomposición SVD

Calculamos la SVD compacta mediante `scipy.linalg.svd(A, full_matrices=False)`:

$$A = U \Sigma V^T = \sum_{r=1}^{n} \sigma_r u_r v_r^T$$

Las dimensiones y propiedades de las matrices obtenidas son:

- $U \in \mathbb{R}^{1907\times 200}$: Vectores singulares izquierdos (columnas ortonormales en $\mathbb{R}^{1907}$, base del espacio columna de A). Error numérico: $\|U^TU - I\|_\infty = 2.22 \times 10^{-15}$.
- $\Sigma \in \mathbb{R}^{200\times 200}$: Matriz diagonal de valores singulares $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_{200} \geq 0$.
- $V^T \in \mathbb{R}^{200\times 200}$: Vectores singulares derechos transpuestos (filas ortonormales en $\mathbb{R}^{200}$, base del espacio fila de A). Error numérico: $\|V^TV - I\|_\infty = 2.00 \times 10^{-15}$.
- Error de reconstrucción de Frobenius: $\|A - U\Sigma V^T\|_F = 3.91 \times 10^{-14}$.

6. Paso 6 – Análisis de Valores Singulares y Elección de k

El **Teorema de Eckart-Young-Mirsky** garantiza que la matriz truncada $A_k = U_k\Sigma_k V_k^T$ es la mejor aproximación de rango k para A bajo las normas espectral y de Frobenius, con un error residual exacto $\|A - A_k\|_F = \sqrt{\sum_{j=k+1}^{n} \sigma_j^2}$.

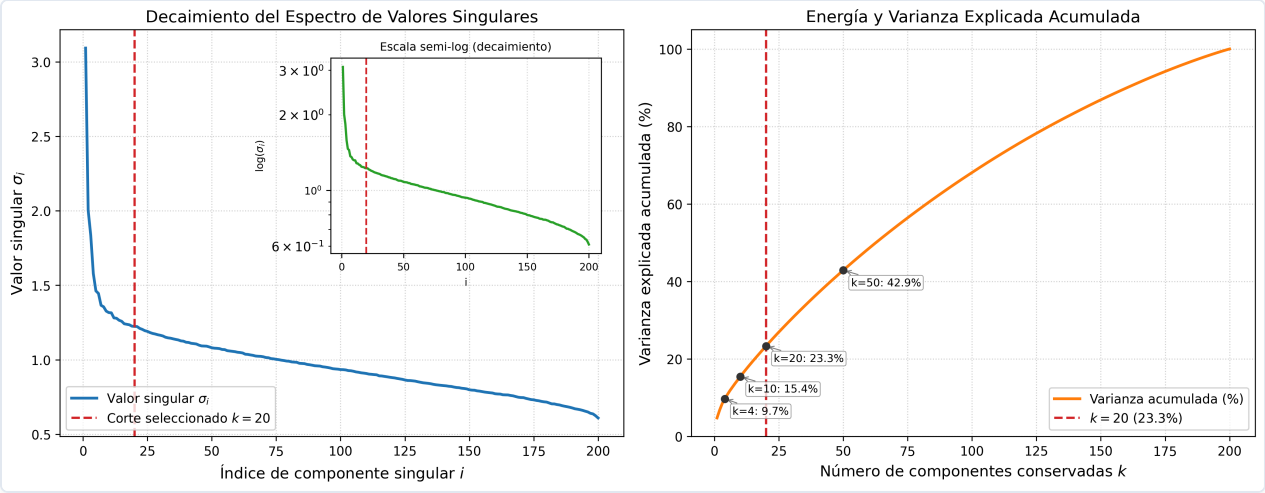


Figura 1: Espectro de valores singulares (con escala semi-logarítmica) y varianza acumulada explicada.

Los valores singulares principales son $\sigma_1 = 3.099$, $\sigma_2 = 2.000$, $\sigma_3 = 1.833$, $\sigma_4 = 1.579$. Con $k = 4$ se separan las 4 macro-disciplinas (9.73% de varianza). Para el análisis latente en profundidad, seleccionamos $k = 20$ (23.32% de varianza), lo cual comprime la dimensión en un 90% ($200 \to 20$), descartando el ruido estocástico de cola y reteniendo las correlaciones semánticas esenciales.

7. Paso 7 – Representación en Baja Dimensión (2D)

Fundamentación Algebraica de las Proyecciones

Proyección de Términos (Filas de A): Cada término i es la fila $r_i^T = e_i^T A$. Su proyección ortogonal en la base ortonormal $\{v_a, v_b\}$ de $\mathrm{Span}(v_a, v_b)$ es:

$$x_i = \langle r_i, v_a \rangle = (e_i^T A)v_a = e_i^T(Av_a) = e_i^T(\sigma_a u_a) = \sigma_a u_a(i)$$

$$y_i = \langle r_i, v_b \rangle = (e_i^T A)v_b = e_i^T(Av_b) = e_i^T(\sigma_b u_b) = \sigma_b u_b(i)$$

Matricialmente: $\text{Coords} = A[v_a \mid v_b] = [\sigma_a u_a \mid \sigma_b u_b]$. Discrepancia numérica observada: 4.31×10^{-15}.

Proyección de Documentos (Columnas de A): Cada documento j es la columna $c_j = Ae_j$. Su proyección en $\{u_a, u_b\}$ es:

$$\xi_j = \langle u_a, c_j \rangle = u_a^T(Ae_j) = (u_a^T A)e_j = (\sigma_a v_a^T)e_j = \sigma_a v_a(j)$$

$$\eta_j = \langle u_b, c_j \rangle = u_b^T(Ae_j) = (u_b^T A)e_j = (\sigma_b v_b^T)e_j = \sigma_b v_b(j)$$

Matricialmente: $\text{Coords} = [u_a \mid u_b]^T A = [\sigma_a v_a \mid \sigma_b v_b]^T$. Discrepancia numérica: 9.02×10^{-16}.

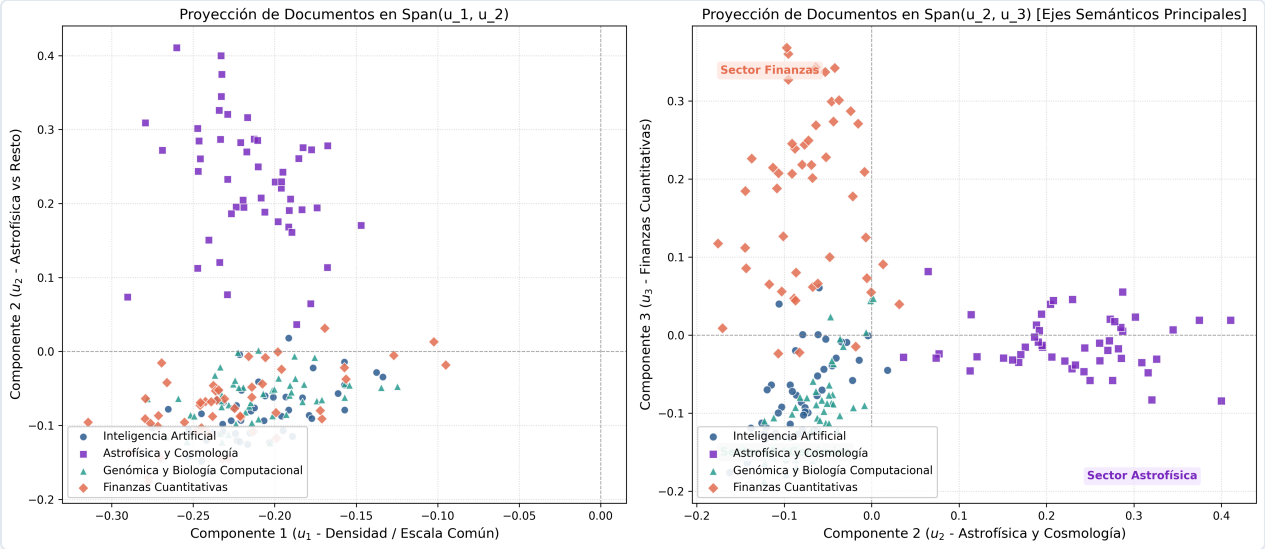


Figura 2: Proyección 2D de documentos en $\text{Span}(u_1, u_2)$ *(izquierda) y* $\text{Span}(u_2, u_3)$ *(derecha).*

En el plano $\text{Span}(u_2, u_3)$, la separación es categórica: Astrofísica se proyecta en el semiplano positivo de u_2, Finanzas se concentra en el semiplano positivo de u_3, e Inteligencia Artificial y Genómica habitan el cuadrante inferior izquierdo.

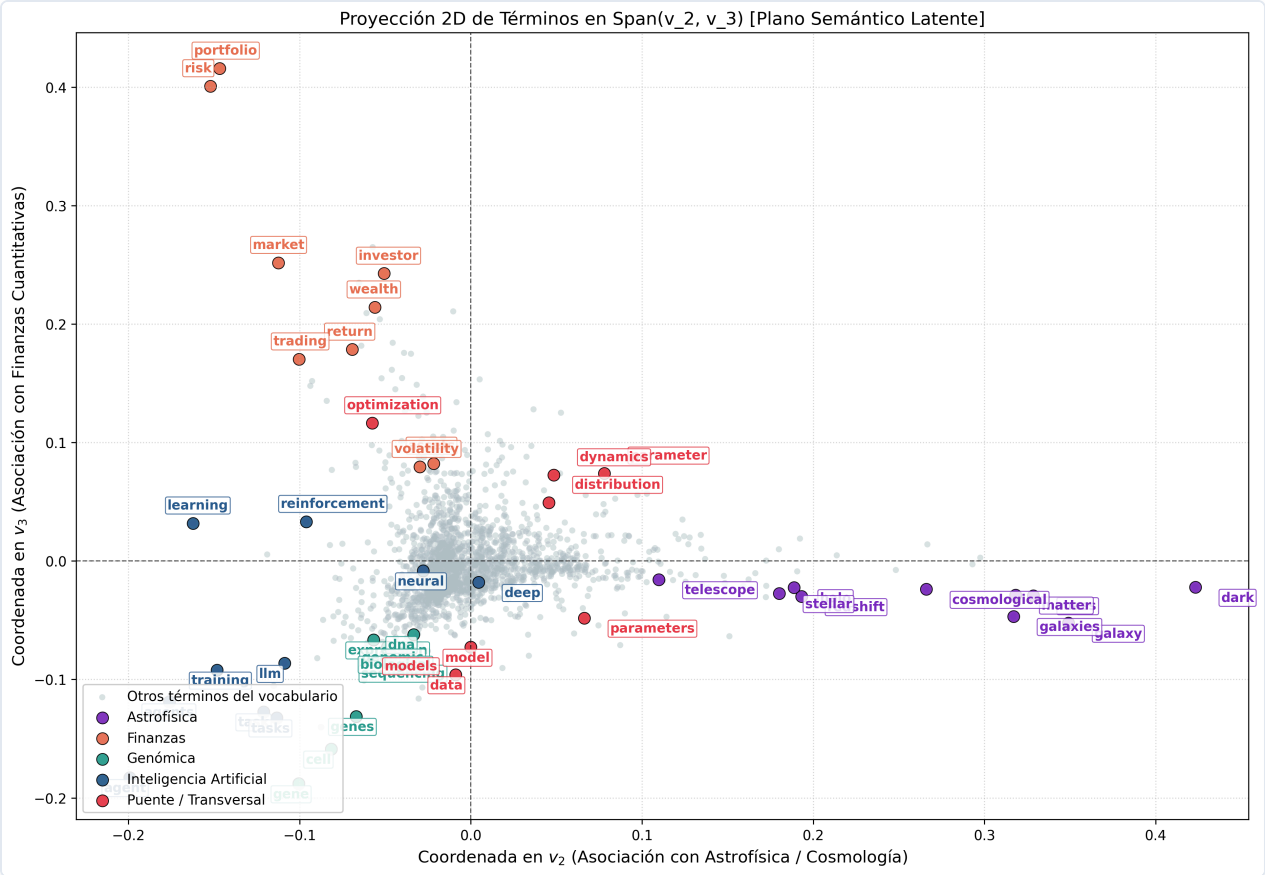


Figura 3: Proyección 2D de términos en $\mathrm{Span}(v_2, v_3)$ *con palabras clave destacadas por disciplina.*

8. Paso 8 – Exploración Semántica

Calculando la similitud coseno en el espacio reducido de dimensión $k = 20$, recuperamos los vecinos semánticos más cercanos:

- `neural` $\rightarrow$ `network` (0.798), `convolutional` (0.732), `networks` (0.727).
- `galaxy` $\rightarrow$ `galaxies` (0.967), `luminous` (0.945), `tidal` (0.942), `lensing` (0.903).
- `gene` $\rightarrow$ `genes` (0.957), `rna` (0.936), `expression` (0.929), `cell` (0.901).
- `portfolio` $\rightarrow$ `return` (0.925), `asset` (0.912), `portfolios` (0.908), `risk` (0.891).
- `model` $\rightarrow$ `likelihood` (0.786), `parameters` (0.734), `fit` (0.766).

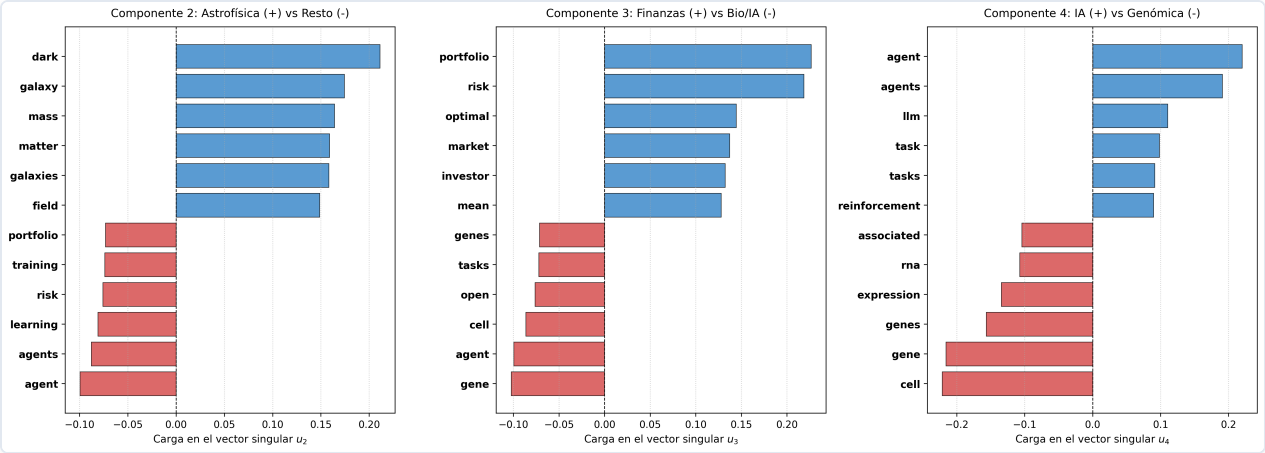


Figura 4: Términos con mayores cargas en los vectores singulares izquierdos u_2, u_3 y u_4.

9. Paso 9 – Discusión, Limitaciones y Conclusiones

Contraste con la Hipótesis: La hipótesis se verificó en su totalidad:

1. El decaimiento espectral confirmó la concentración de la información en componentes bajas.
2. La componente 1 actuó como un eje de masa léxica común, mientras que u_2, u_3, u_4 aislaron de manera no supervisada los 4 tópicos.
3. Palabras puente como *model, parameters, distribution* se posicionaron en el origen, demostrando su naturaleza transversal.

Límites del Modelo: LSA asume linealidad y ortogonalidad estricta entre tópicos (lo que no siempre ocurre en la ciencia interdisciplinaria) e ignora el orden gramatical de las oraciones. Además, las componentes singulares admiten valores negativos, lo que impide interpretarlas directamente como distribuciones probabilísticas puras.

Conclusión: La Descomposición en Valores Singulares demuestra ser un método analítico formidable, transformando matrices no estructuradas en representaciones geométricas interpretables mediante la elegancia del álgebra lineal.

Checklist de Entrega

Ítem Exigido en la Pauta	Estado	Ubicación en el Proyecto
Corpus descrito y fuente citada	✓ **Cumplido**	Sección 2 e informe, `data/corpus.csv`
Hipótesis inicial formulada	✓ **Cumplido**	Sección 3 e informe

Ítem Exigido en la Pauta	Estado	Ubicación en el Proyecto
Matriz término-documento construida	✓ **Cumplido**	Sección 4, `src/preprocessing.py` (1907×200)
SVD calculada con parámetros	✓ **Cumplido**	Sección 5, `src/svd_analysis.py`
Gráfico de valores singulares	✓ **Cumplido**	Figura 1, `figures/01_singular_values_decay.png`
Visualización 2D de documentos	✓ **Cumplido**	Figura 2, `figures/03_documents_2d_projection.png`
Visualización 2D de palabras o términos	✓ **Cumplido**	Figura 3, `figures/04_terms_2d_projection.png`
Ejemplos de exploración semántica	✓ **Cumplido**	Sección 8, `src/semantic_exploration.py`
Discusión final y limitaciones	✓ **Cumplido**	Sección 9 e informe
Código reproducible en GitHub	✓ **Cumplido**	Repositorio: `damian11daba/proyecto-avanzada-y-modelamiento`